

Projet de Recherche en Laboratoire :

Comment un autoencodeur apprend-t-il une dynamique non-linéaire complexe ?

Leo Flack

Septembre 2025 - Mars 2026




Table des matières

Introduction	3
1 Objectifs, choix des données, et analyse spectrale	4
1.1 Choix des données et modèle génératif	5
1.2 Templates et régularité	5
1.3 Spectres de covariance	7
2 Architectures de réseaux et apprentissage	8
2.1 PCA et limites de l'approche linéaire	8
2.2 Capacité de généralisation	10
3 Résolution analytique par la méthode des répliques	12
3.1 Formalisme, fonction de partition et paramètres d'ordre	13
3.2 Action effective et élimination des champs conjugués	15
3.3 Ansatz de symétrie des répliques (RS) et action réduite	15
3.4 Équations du col et détermination des paramètres d'ordre	16
3.5 Énergie libre, erreur d'entraînement et entropie	16
Conclusion	17
Références	19
4 Annexe : calcul complet des répliques	20

Introduction

L'apprentissage profond démontre des capacités empiriques remarquables pour capturer des distributions de données complexes en grande dimension. Toutefois, la compréhension théorique des mécanismes permettant à ces architectures de généraliser demeure un défi. La physique statistique des systèmes désordonnés, en traitant l'apprentissage comme un système à l'équilibre thermodynamique, offre un cadre théorique pour analyser ces phénomènes. Ce rapport de PRL s'inscrit dans cette démarche et retrace l'étude analytique et numérique menée cette année sur la capacité d'un réseau de neurone du type auto-encodeur à encoder et à reconstruire des données de haute dimension vivant sur un manifold non linéaire de basse dimension, comme les mouvements issus de la rotation spatiale d'objets complexes.

La définition et le choix du système d'étude ont constitué la première étape de ce travail. Afin d'isoler mathématiquement le problème de l'apprentissage d'un manifold non-linéaire, nous avons généré un ensemble de données synthétiques constituées de séquences vidéos de dimension $N = d^2T$ générées par la rotation d'un motif bidimensionnel (le template) à une vitesse angulaire ω variable. Ce cadre contrôlé a permis de faire varier de manière systématique la topologie de l'objet observé via le choix du template (objets lisses infiniténalement dérivables géométriquement, tels qu'une distribution gaussienne, ou objets discontinus à bords francs, comme une croix) pour étudier l'impact de ces caractéristiques topologiques sur l'apprentissage.

L'investigation s'est d'abord construite sur une exploration numérique et algorithmique. Les tentatives initiales de réduction de dimension par des méthodes linéaires classiques (Analyse en Composantes Principales) ainsi que par des auto-encodeurs symétriques peu profonds (shallow) ont mis en évidence une incapacité structurelle à inverser la non-linéarité de la transformation physique. Ces échecs ont motivé l'élaboration d'une architecture asymétrique spécifique : un encodeur shallow couplé à un décodeur profond, forçant le réseau à extraire la variable à moindre coût mais lui donnant la latitude nécessaire pour reconstruire la forte non-linéarité des données étudiées. Des expériences d'interpolation, consistant à évaluer l'erreur du modèle sur une plage de vitesses angulaires exclue du jeu d'entraînement, ont alors révélé une dichotomie stricte. La capacité de généralisation s'est avérée excellente pour les templates géométriquement lisses, mais catastrophique pour les objets présentant un spectre complexe.

Pour dépasser ces observations empiriques et prouver formellement le lien entre la géométrie de la donnée et l'erreur suite à l'apprentissage, la seconde phase du projet a consisté à développer un cadre analytique exact : en isolant l'encodeur linéaire, le calcul de l'erreur d'entraînement a été mené dans la limite thermodynamique via la méthode des répliques. Cette résolution a nécessité un calcul poussé et nous a permis de prendre en compte la quantité de données disponibles via le paramètre $\alpha = \frac{M}{N}$ avec M le nombre de datapoints et N la dimension de l'espace ambiant, forçant une distinction entre les régimes sous-paramétré et sur-paramétré et imposant l'introduction d'un terme de régularisation pour briser la dégénérescence des solutions et stabiliser le système d'équations

du point col.

Ce rapport retrace ce cheminement scientifique. Le premier chapitre définit le modèle de données, justifie les choix topologiques effectués et caractérise la régularité des templates via la densité spectrale de leur matrice de covariance. Le deuxième chapitre expose les itérations architecturales et les résultats des simulations numériques, illustrant empiriquement l'impact de la topologie sur la capacité d'interpolation du modèle. Enfin, le troisième chapitre détaille la résolution théorique par la méthode des répliques, unifiant l'ensemble des travaux de l'année en démontrant analytiquement que la dynamique d'erreur est gouvernée par le spectre du template.




FIGURE 1 – Architecture minimaliste d'un auto-encodeur symétrique à trois couches. L'encodeur et le décodeur partagent une complexité structurelle équivalente de part et d'autre du goulot d'étranglement.

1 Objectifs, choix des données, et analyse spectrale

Le premier choix de cette étude a été celui des données à étudier : il s'agissait de choisir des données de haute dimension vivant sur un manifold de basse dimension, idéalement de dimension 1 pour simplifier l'étude. Plusieurs options ont été considérées, comme l'étude d'un jeu de données "physiques" (e.g. : repliement de protéine) ou un jeu de données informatiques classiques (e.g. : MNIST). Cependant l'étude théorique de l'apprentissage requiert un environnement de données dont les propriétés sont parfaitement maîtrisées : plutôt que d'employer des jeux de données empiriques classiques de vision par ordinateur, intrinsèquement complexes à caractériser analytiquement, la démarche adoptée au cours de cette année s'est fondée sur la construction d'un modèle génératif synthétique. Ce choix méthodologique a permis d'isoler l'impact de la topologie de l'objet étudié sur la dynamique d'apprentissage et la capacité de généralisation du modèle.

1.1 Choix des données et modèle génératif

Le système physique modélisé repose sur un objet spatial bidimensionnel de référence, désigné sous le terme de *template* et noté S^0 . Cet objet est défini sur une grille spatiale discrète de dimension $d \times d$. Un datapoint est défini comme une "vidéo" constitué de T images, la dynamique du système étant engendrée par rotation spatiale du template autour du centre de la grille. Ainsi un datapoint est paramétré de manière univoque par une vitesse angulaire ω . La distribution des données est donc déterminée par la distribution des ω .

Mathématiquement, chaque datapoint est modélisé par un vecteur d'entrée $\phi(\omega) \in \mathbb{R}^N$, où la dimension totale de l'espace de plongement est $N = d^2 T$. Lors des différentes expériences numériques réalisées pour valider ce modèle, les dimensions ont typiquement été fixées à $d = 28$ et $T = 10$ images, conduisant à un espace d'observation de dimension $N = 7840$.

L'ensemble des données d'apprentissage et de test est généré en échantillonnant la vitesse angulaire ω selon une distribution de probabilité $\rho(\omega)$, qui correspondra pour cette étude soit à la distribution uniforme sur $[0, \omega_{max}]$ avec $\omega_{max} = \frac{2*\pi}{T}$ (un tour maximum), soit à une distribution en "créneau" (uniforme sur $[0, \frac{\omega_{max}}{3}] \cup [\frac{2\omega_{max}}{3}, \omega_{max}]$) en laissant un gap de valeur destiné au test. La variation continue de cette unique variable latente ω engendre une variété (manifold) unidimensionnelle plongée dans l'espace de grande dimension $\mathbb{R}^N$.

La pertinence physique de ce modèle génératif réside dans la nature de l'application $\omega \mapsto \phi(\omega)$. Bien que le mouvement physique soit paramétré par un unique degré de liberté (le scalaire ω), l'évolution de l'intensité d'un pixel donné au cours du temps constitue une fonction hautement non-linéaire de ω , dépendant des coordonnées spatiales initiales de ce pixel. Le réseau de neurones fait donc face au problème complexe de l'inversion d'une variété fortement repliée sur elle-même.

En outre, ce cadre formel offre la souplesse nécessaire pour tester de multiples hypothèses topologiques. En modifiant simplement la distribution spatiale des intensités du template initial S^0 , il devient possible de contrôler la variété générée. L'étude s'est ainsi portée sur une gradation de templates, allant d'objets lisses et continus à des formes présentant des discontinuités topologiques ou des symétries discrètes, dont l'impact s'est avéré déterminant pour la généralisation de l'encodeur.

1.2 Templates et régularité

Afin d'établir un lien formel entre la géométrie intrinsèque de l'objet physique et la difficulté de l'apprentissage de la variété associée, il a été nécessaire de performer des expériences numériques sur un vaste champs de templates et de définir ainsi de nombreux templates présentant des différences topologiques importantes. Cette famille d'objets bi-dimensionnels a été conçue pour balayer un spectre d'attributs variés, allant de la régularité analytique stricte à l'introduction de discontinuités franches, tout en incluant des contraintes de symétrie.

Le panel de templates étudié au cours de ces travaux comprend les éléments suivants :

- Une distribution gaussienne décentrée : elle modélise un objet géométriquement lisse, de classe infiniténalement dérivable, dépourvu de bords nets.
- Un quart de cercle : il introduit des discontinuités strictes, tant radiales qu'angulaires (bords francs et coins), tout en présentant une asymétrie totale par rapport au centre de rotation.
- Une croix centrée : cet objet combine des discontinuités fortes (arêtes nettes) avec une symétrie de rotation discrète d'ordre quatre, son information étant redondante par rotations de quatre-vingt-dix degrés.
- Un dipôle : constitué de deux taches gaussiennes diamétralement opposées, il permet d'étudier l'effet d'une symétrie d'ordre deux sur une topologie par ailleurs parfaitement lisse.
- Un disque uniforme centré : cet objet, strictement invariant par rotation, a été inclus comme témoin négatif afin de valider les implémentations numériques.




FIGURE 2 – Exemples de templates et évolution

Afin de formaliser mathématiquement la notion de régularité spatiale introduite précédemment, considérons le cas de la distribution gaussienne décentrée. Soit un *template* $s_0(x, y)$ défini par une tache gaussienne de variance σ^2 , dont le centre est décalé d'une distance r_0 sur l'axe des abscisses. En coordonnées cartésiennes, l'intensité d'un pixel s'écrit :

$$s_0(x, y) = \exp\left(-\frac{(x - r_0)^2 + y^2}{2\sigma^2}\right) \quad (1)$$

Puisque la dynamique fondamentale du système est une rotation, il est naturel d'adopter un système de coordonnées polaires (r, θ) , où $x = r \cos \theta$ et $y = r \sin \theta$. En développant le terme quadratique, le *template* se factorise en un terme purement radial et un terme de couplage angulaire :

$$s_0(r, \theta) = \exp\left(-\frac{r^2 + r_0^2}{2\sigma^2}\right) \exp\left(\frac{rr_0}{\sigma^2} \cos \theta\right) \quad (2)$$

Pour séparer formellement la géométrie radiale de la dépendance angulaire, nous faisons appel à l'identité de Jacobi-Anger. En posant l'atténuation radiale globale $A(r) = \exp\left(-\frac{r^2 + r_0^2}{2\sigma^2}\right)$ et le facteur d'excentricité $z(r) = \frac{rr_0}{\sigma^2}$, l'exponentielle du cosinus se décom-

pose en une série de Fourier spatiale exacte :

$$s_0(r, \theta) = A(r) \sum_{k=-\infty}^{+\infty} I_k(z(r)) e^{ik\theta} \quad (3)$$

où $I_k(z)$ désigne la fonction de Bessel modifiée de première espèce d'ordre k .

La séquence vidéo d'entrée $\phi(r, \theta, t, \omega)$ correspond à la rotation de cet objet à la vitesse angulaire ω . À l'instant t , l'image a tourné d'un angle ωt , ce qui se traduit par un décalage de phase temporel :

$$\phi(r, \theta, t, \omega) = s_0(r, \theta - \omega t) = A(r) \sum_{k=-\infty}^{+\infty} I_k(z(r)) e^{ik\theta} e^{-ik\omega t} \quad (4)$$

Cette formulation analytique révèle la nature de la variété générée. L'information temporelle et la variable latente ω sont strictement isolées dans l'exponentielle complexe, tandis que l'amplitude de chaque mode spatial (chaque fréquence k) est gouvernée par la fonction de Bessel $I_k(z(r))$. Or, pour un argument z fixé, $I_k(z)$ décroît de manière factorielle lorsque l'ordre k augmente. Cela prouve formellement que l'énergie d'un *template* lisse est presque intégralement confinée dans ses tous premiers modes de Fourier. La variété non-linéaire étudiée, bien que plongée dans $\mathbb{R}^N$, se déploie donc dans un sous-espace fonctionnel de dimension drastiquement réduite, ce qui justifiera ultérieurement l'effondrement rapide du spectre de covariance.

1.3 Spectres de covariance

La caractérisation topologique des objets introduite précédemment trouve sa traduction algébrique directe dans l'étude de la matrice de covariance des données. Cette étape analytique est fondamentale car elle préfigure la capacité de généralisation du modèle.

Pour un ensemble de rotations échantillonnées selon une distribution de probabilité, on définit la matrice de covariance empirique des entrées $\mathcal{M} = \langle \phi(\omega) \phi(\omega)^T \rangle_\omega$, de dimension $N \times N$, ainsi que le vecteur de corrélation entrée-sortie $C = \langle \omega \phi(\omega) \rangle_\omega$. L'opérateur $\mathcal{M}$ encapsule l'intégralité de l'information géométrique de la variété générée par le template. La difficulté algorithmique de l'apprentissage est intimement liée au spectre de ses valeurs propres λ_k et à la forme de sa densité spectrale.

L'analyse spectrale menée empiriquement sur les différents templates a révélé une dichotomie stricte dictée par la transformée de Fourier spatiale des objets.

Dans le cas des objets géométriquement lisses, tels que la distribution gaussienne ou le dipôle, le spectre de covariance exhibe un effondrement extrêmement rapide. Les valeurs propres λ_k suivent une décroissance exponentielle, et la dimension de la variété est alors infime en comparaison de l'espace de plongement : une trentaine de modes propres significatifs suffisent à reconstruire l'intégralité de la dynamique sur les 7840 dimensions disponibles.

La mise en œuvre des inversions matricielles s'est heurtée à des artefacts numériques :

la décroissance exponentielle du spectre pour les templates lisses engendre très rapidement des valeurs propres inférieures à la précision machine standard, ce qui provoque l'échec des solveurs classiques ; pour surmonter cet écueil, il a été nécessaire de substituer l'inversion directe par une décomposition en valeurs singulières tronquée énergétiquement. Seuls les modes propres capturant plus de 99.9% de la variance totale du signal ont été conservés. Un seuil de tolérance relative (cut-off) a été appliqué : les modes propres λ_k dont l'énergie relative λ_k/λ_{max} est inférieure à un seuil critique (fixé empiriquement à 10^{-4} pour le calcul des poids, et 10^{-12} pour l'observation des densités) sont annihilés. Ce filtrage spectral, analogue à une troncature énergétique, garantit que seuls les degrés de liberté capturant la variance physique (donc la dynamique réelle de la rotation) participent à la construction des poids, assurant ainsi la robustesse de l'expérience.

À l'inverse, pour les templates présentant des discontinuités topologiques comme la croix, le spectre de $\mathcal{M}$ présente une décroissance algébrique très lente, suivant une loi de puissance. Physiquement, le codage d'un bord franc en mouvement de rotation requiert l'activation de nombreuses hautes fréquences spatiales. La variété ne se résume plus à un sous-espace de basse dimension confiné.

Par ailleurs, le fléau de la dimension ($N = 7840$) lié à la nécessité d'explorer le régime sur-paramétré avec de vastes ensembles de données a rendu la génération séquentielle des rotations sur CPU prohibitive en temps de calcul. L'intégralité de la génération a dû être parallélisée sur GPU, permettant de simuler l'ensemble du manifold de manière quasi instantanée.

Les observations ont également permis d'isoler l'impact strict des symétries géométriques. L'introduction d'une symétrie de rotation d'ordre quatre, dans le cas de la croix, diminue drastiquement le nombre de modes propres dominants par rapport à un objet asymétrique tel que le quart de cercle, l'information redondante sur quatre-vingt-dix degrés n'engendrant pas de nouvelles dimensions latentes. Néanmoins, cette compression globale n'efface pas la queue lourde du spectre, qui demeure invariablement dictée par les discontinuités locales.

2 Architectures de réseaux et apprentissage

Avant d'aborder la résolution analytique du problème, il s'agit de justifier empiriquement nos choix d'architecture et nos hypothèses. Ce chapitre expose la démarche numérique ayant conduit à l'adoption d'un encodage une couche (shallow) couplé à un décodage profond, un choix dicté par la nature asymétrique de la tâche de l'autoencodeur.

2.1 PCA et limites de l'approche linéaire

La première étape de l'investigation numérique a consisté à évaluer la capacité des méthodes de réduction de dimension classiques à extraire le paramètre cinématique latent. L'Analyse en Composantes Principales (PCA) a servi de modèle de référence. On note qu'il s'agit là d'une approche équivalente à l'adoption d'une architecture d'autoencodeur




FIGURE 3 – Reconstruction pour un autoencodeur à 3 ou 5 couches, template "arc de cercle"

linéaire - linéaire, selon un résultat classique.

Appliquée aux données générées par la rotation du template, l'analyse révèle que la projection sur le premier axe principal trace une sinusoïde quasi-parfaite en fonction de la vitesse angulaire ω (avec un coefficient de détermination $R^2 \approx 0.9999$). La projection unidimensionnelle résultante (une sinusoïde) n'est pas bijective.

Ce constat empirique ne disqualifie pas pour autant l'utilisation d'une projection linéaire, la problématique résidant dans l'objectif d'optimisation. Nos expériences numériques, guidés par l'idée théorique que l'extraction de la vitesse angulaire est un problème non-linéaire suffisamment "simple" pour être approché par un encodeur linéaire, ont démontré que pour obtenir une reconstruction satisfaisante du vecteur d'entrée, il suffit en effet d'extraire la variable latente via un encodeur shallow linéaire tant que l'on permet au modèle d'obtenir la non-linéarité nécessaire à la reconstruction du vecteur hautement non-linéaire en (x,y,t) , via un décodeur profond avec fonctions d'activations non-linéaires.

Les simulations numériques menées sur un auto-encodeur asymétrique (encodeur strictement linéaire vers un espace latent $z \in \mathbb{R}$, suivi d'un décodeur profond constitué de plusieurs couches denses non-linéaires) le montrent : l'analyse de l'espace latent démontre l'émergence d'une relation strictement monotone et fortement bijective entre l'activation du neurone goulot z et la véritable vitesse angulaire ω . L'encodeur linéaire parvient ainsi à extraire l'information pertinente tandis que la reconstruction hautement non-linéaire des pixels de l'image (l'inversion de la rotation) est intégralement portée par le décodeur profond.

Ce succès empirique est la raison qui nous a poussé à développer la théorie donnée en




FIGURE 4 – Haut : PCA1. Bas : variable latente de l'AE

partie III, qui suppose un encodeur linéaire et cherche à déterminer sa capacité à capturer la variable latente qu'est la vitesse angulaire. En prouvant qu'une projection linéaire ciblée est matériellement suffisante pour extraire l'information sur ce type de variété, l'analyse mathématique de l'encodeur peut être strictement découplée et réduite à un problème de régression linéaire, soluble par les outils de la physique statistique.

2.2 Capacité de généralisation

Ayant validé l'aptitude d'une projection linéaire à extraire la variable latente sur l'intégralité du domaine d'entraînement, l'étude s'est orientée vers l'évaluation de la capacité de généralisation du modèle. Celle-ci se manifeste par la capacité du modèle à interpoler la dynamique dans des régions de l'espace des phases non explorées lors de la phase




FIGURE 5 – Architecture asymétrique. L’encodeur extrait l’information latente via une unique projection peu profonde (*shallow*), tandis que la tâche complexe de reconstruction spatiale est entièrement déportée sur un décodeur profond (*deep*) et hautement non-linéaire.

d’apprentissage.

Pour quantifier cette propriété, le protocole conçu consiste à entraîner le modèle avec un domaine d’exclusion, ou gap d’échantillonnage. Un encodeur linéaire est optimisé pour capturer la vitesse angulaire ω sur un jeu d’entraînement est délibérément tronqué : les données correspondant à une plage centrale de vitesses angulaires sont exclues. L’erreur quadratique moyenne de test, notée $\mathcal{E}(\omega)$, est ensuite mesurée sur l’ensemble du domaine continu, et tout particulièrement au sein de la zone d’exclusion.

Les résultats de ces expériences numériques ont mis en évidence une dichotomie stricte, dictée par la régularité topologique des templates préalablement caractérisée.

Dans le cas des objets géométriquement lisses tels que la distribution gaussienne, l’erreur de test mesurée demeure négligeable tout au long du domaine, y compris à l’intérieur du gap. L’encodeur linéaire parvient à interpoler parfaitement la trajectoire manquante. Ce succès s’explique par la nature analytique de la variété mise en évidence au chapitre précédent qui garantit que l’intégralité de l’information dynamique est contenue dans un nombre très restreint de modes. Les données présentes aux bornes du gap suffisent mathématiquement à contraindre ces quelques degrés de liberté, permettant une interpolation stable.

À l’inverse, pour les objets présentant des discontinuités topologiques franches (segment, quart de cercle, croix), l’interpolation s’avère catastrophique. Bien que l’erreur d’entraînement reste virtuellement nulle hors de la zone d’exclusion, l’erreur de test explose massivement à l’intérieur du gap. Privé de données locales, l’estimateur linéaire se révèle incapable de déduire la cinématique de la rotation.




FIGURE 6 – Spectre de covariance et erreur de generalisation pour la tâche gaussienne et le segment

Cet d'échec local trouve une explication dans la structure en queue lourde du spectre de covariance de ces objets discontinus. La présence de bords nets requiert l'activation d'une infinité de modes de hautes fréquences spatiales pour être encodée linéairement. En l'absence de données d'entraînement dans le gap, le système devient sous-contraint. Les coefficients de projection associés à ces modes de hautes fréquences ne sont plus régularisés par la cinématique et subissent des fluctuations incontrôlées. Cette instabilité est analogue au phénomène de Runge observé dans l'interpolation polynomiale de haut degré : le modèle dispose de degrés de liberté excessifs qui, n'étant plus ancrés par des points de données dans le gap d'échantillonnage, divergent violemment. C'est la lente décroissance spectrale inhérente aux discontinuités de l'objet qui fournit ces modes hautement oscillants à l'estimateur. L'erreur de généralisation d'un modèle linéaire est donc bornée par la régularité spatiale de l'objet physique observé.

3 Résolution analytique par la méthode des répliques

Nous nous sommes ramené au cas d'un encodeur linéaire visant à apprendre à capturer la variable latente ω . Il s'agit d'un problème d'apprentissage linéaire supervisé, pour lequel nous pouvons faire appel aux méthodes développées par la physique statistique, dont la méthode des répliques. Cette section du rapport détaille la résolution mathématique exacte du modèle d'apprentissage de la variable ω par l'encodeur linéaire. L'objectif y est




FIGURE 7 – Spectre de covariance et erreur de generalisation pour le quart de cercle et la croix

de dériver analytiquement l’erreur d’entraînement et l’erreur de test, avec un terme de régularisation Ridge (qui nous évite de devoir prendre en compte le paramètre d’entraînement) ainsi que les paramètres d’ordre macroscopiques du système, dans le but de mettre en évidence la dépendance de l’apprentissage en $\alpha = \frac{M}{N}$ et en le template caractérisé par sa matrice de covariance. La section suivante ne présente que les étapes principales d’un calcul de répliques trop long pour être intégré ici, que le lecteur pourra trouver intégralement en annexe.

3.1 Formalisme, fonction de partition et paramètres d’ordre

Considérons un ensemble de M données d’entraînement constituées des vecteurs d’entrée $\phi(\omega_\mu)$ de dimension $N = d^2T$, générés par un template en rotation à la vitesse ω_μ . L’encodeur linéaire est paramétré par un vecteur de poids $W \in \mathbb{R}^N$. La fonction de coût, ou Hamiltonien du système, mesurant l’erreur quadratique de prédiction sur le jeu d’entraînement, s’écrit :

$$H(W) = \frac{1}{2} \sum_{\mu=1}^M (\omega_\mu - W \cdot \phi(\omega_\mu))^2 + \frac{\lambda}{2} \text{Tr}(WW^T) \quad (5)$$

Dans le cadre de la physique statistique, l’apprentissage est modélisé par une distribution de Boltzmann sur l’espace des poids, régie par un paramètre de température inverse

β . On s'intéresse dans notre cas à un apprentissage à température nulle, on prend donc $\beta \rightarrow \infty$ à la fin du calcul. La fonction de partition totale associée à un jeu de données fixé (désordre gelé) $\{\omega_\mu\}$ est :

$$Z(\{\omega_\mu\}) = \int dW e^{-\frac{\beta}{2} \sum_{\mu=1}^M (\omega_\mu - W \cdot \phi(\omega_\mu))^2 - \gamma (\omega_t - W \cdot \phi(\omega_t))^2 - \frac{\lambda}{2} \text{Tr}(WW^T)}$$

où l'on a ajouté un terme de test $\gamma (\omega_t - W \cdot \phi(\omega_t))^2$, avec $\gamma =_{\beta \rightarrow \infty} o(\beta)$, qui nous donnera l'erreur de test en dérivant par rapport à ce paramètre.

Le calcul de répliques est dans ce rapport mené dans sa forme fondamentale, sans terme de régularisation et sans terme de test ($\gamma = \lambda = 0$), afin d'étudier dans le cadre théorique le plus solvable possible les dépendances en *alpha* et en le template dans l'erreur (d'entraînement donc) de notre encodeur ; ce premier calcul complet de répliques pave la voie vers un calcul donnant l'erreur de test, en ajoutant simplement les termes présentés ci-dessus dans le hamiltonien. On a donc ici :

$$Z(\{\omega_\mu\}) = \int dW \exp \left(-\frac{\beta}{2} \sum_{\mu=1}^M (\omega_\mu - W \cdot \phi(\omega_\mu))^2 \right) \quad (6)$$

Pour évaluer les propriétés typiques du système, il est nécessaire de calculer l'énergie libre moyenne sur l'ensemble des réalisations du désordre (car c'est une grandeur auto-moyennante). L'évaluation directe de $\langle \ln Z \rangle$ étant mathématiquement intraitable, nous allons utiliser l'identité des répliques : $\langle \ln Z \rangle = \lim_{n \rightarrow 0} \frac{\langle Z^n \rangle - 1}{n}$. Il s'agit alors de calculer Z^n pour un n entier, puis de passer à la limite $n \rightarrow 0$ dans le calcul de la fonction de partition.

La moyenne de la fonction de partition pour n répliques indépendantes s'exprime comme :

$$\langle Z^n \rangle = \int \prod_{a=1}^n dW^a \left(\left\langle \exp \left(-\frac{\beta}{2} \sum_{a=1}^n (\omega - W^a \cdot \phi(\omega))^2 \right) \right\rangle_{\omega, \phi} \right)^M \quad (7)$$

Nous devons à ce stade faire une hypothèse simplificatrice fondamentale pour rendre le problème solvable analytiquement : le vecteur conjoint composé de l'entrée et de la cible est modélisé par une distribution gaussienne multivariée. En définissant la matrice de covariance empirique $\mathcal{M} = \langle \phi(\omega) \phi(\omega)^T \rangle$, le vecteur de corrélation $C = \langle \omega \phi(\omega) \rangle$ et la variance σ_ω^2 , le vecteur aléatoire conjoint suit une loi normale :

$$\begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix} \sim \mathcal{N} \left(\begin{pmatrix} \bar{\phi} \\ \bar{\omega} \end{pmatrix}, \begin{pmatrix} \mathcal{M} & C \\ C^T & \sigma_\omega^2 \end{pmatrix} \right) \quad (8)$$

Afin de linéariser le terme quadratique dans l'exponentielle, nous introduisons un vecteur auxiliaire gaussien $\vec{z} \sim \mathcal{N}(\vec{0}, \beta \mathbb{I}_n)$. L'intégration sur le désordre devient alors une intégrale gaussienne exacte.

Au terme de cette intégration, les couplages entre les répliques apparaissent naturellement et motivent l'introduction des paramètres d'ordre macroscopiques :

$$q_i^{a,b} = (W^a)^T \mathcal{M} W^b, \quad m^a = -C \cdot W^a, \quad \tilde{q}^a = \bar{\omega} - \bar{\phi} \cdot W^a \quad (9)$$

Ces paramètres définissent la matrice globale d'interaction $q^{a,b} = q_i^{a,b} + m^a + m^b + \sigma_\omega^2$.

L'intégration finale sur le vecteur auxiliaire $\vec{z}$ produit un terme de déterminant :

$$\left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle = \frac{\exp\left(-\frac{\beta}{2} \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q}\right)}{\sqrt{\det(\mathbb{I}_n + \beta q)}} \quad (10)$$

3.2 Action effective et élimination des champs conjugués

L'intégrale sur les configurations microscopiques des poids W^a est remplacée par une intégrale sur les paramètres d'ordre macroscopiques q_i , m et $\tilde{q}$ par l'insertion de distributions de Dirac sous forme de Fourier, introduisant les variables conjuguées $\hat{q}_i$, $\hat{m}$ et $\hat{\tilde{q}}$. En définissant les constantes de projection du signal sur la métrique des données $\mathcal{J}_{\phi\phi} = \bar{\phi}^T \Sigma \bar{\phi}$, $\mathcal{J}_{\phi c} = \bar{\phi}^T \Sigma C$ et $\mathcal{J}_{cc} = C^T \Sigma C$, avec $\Sigma = M^{-1}$, l'intégrale sur les répliques se réécrit $\langle Z^n \rangle \propto \int \exp(-S) dq_i d\hat{q}_i dm d\hat{m} d\tilde{q} d\hat{\tilde{q}}$ avec une action S .

Pour simplifier l'action effective S , les variables d'ordre et de corrélation sont regroupées sous forme matricielle. On pose $X = (m \mid \tilde{q} - \bar{\omega} \mathbb{I}_n)$, $J = (\hat{m} \mid \hat{\tilde{q}})$ et $A = \begin{pmatrix} \mathcal{J}_{cc} & \mathcal{J}_{\phi c} \\ \mathcal{J}_{\phi c} & \mathcal{J}_{\phi\phi} \end{pmatrix}$ (A contient l'information sur la topologie du template). La partie conjuguée de l'action s'écrit alors :

$$S_{conj} = -\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) - \text{Tr}(J^T X) - \frac{1}{2} \text{Tr}(J^T \hat{q}_i^{-1} J A) + \frac{N}{2} \ln \det \hat{q}_i \quad (11)$$

Dans la limite thermodynamique $N \rightarrow \infty$, l'intégrale est dominée par le point col. L'annulation des dérivées par rapport aux champs conjugués donne $J = -\hat{q}_i X A^{-1}$ et $\hat{q}_i^{-1} = \frac{1}{N} (q_i - X A^{-1} X^T)$. La substitution de ces solutions exactes permet d'éliminer totalement les champs conjugués, conduisant à une action effective finale ne dépendant plus que des paramètres physiques :

$$S_{eff} = \frac{\beta M}{2} \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} + \frac{M}{2} \ln \det(\mathbb{I}_n + \beta q) - \frac{N}{2} \ln \det (q_i - X A^{-1} X^T) \quad (12)$$

3.3 Ansatz de symétrie des répliques (RS) et action réduite

Pour évaluer la limite $n \rightarrow 0$, l'ansatz de symétrie des répliques (Replica Symmetry) est imposé. L'équivalence statistique entre les répliques de notre système dicte l'hypothèse suivante : $q_i^{a=b} = Q_i$ et $q_i^{a \neq b} = q_{i0}$. On définit la variance inter-répliques $\delta q = Q_i - q_{i0}$ et la norme globale $q_0 = q_{i0} + 2m + \sigma_\omega^2$. Les vecteurs d'ordre s'homogénéisent en $m^a = m$ et $\tilde{q}^a = \tilde{q}$.

Sous cet ansatz, la matrice X possède des lignes identiques. Le produit matriciel

$XA^{-1}X^T$ devient proportionnel à la matrice pleine $\mathbb{J}_n$, s'écrivant $c(m, \tilde{q})\mathbb{J}_n$ avec :

$$c(m, \tilde{q}) = m^2(A^{-1})_{11} + 2m(\tilde{q} - \bar{\omega})(A^{-1})_{12} + (\tilde{q} - \bar{\omega})^2(A^{-1})_{22} \quad (13)$$

Cette structure permet de diagonaliser analytiquement l'argument du logarithme : la matrice à inverser prend la forme formelle $(Q_i - q_{i0})\mathbb{I}_n + (q_{i0} - c)\mathbb{J}_n$. L'évaluation des déterminants et le développement limité à l'ordre un en n livre l'action effective par réplique $S_{eff}^{RS} = \lim_{n \rightarrow 0} \frac{S_{eff}}{n}$, exprimée en fonction du rapport $\alpha = \frac{M}{N}$:

$$\begin{aligned} \frac{1}{N} S_{eff}^{RS} &= \frac{\alpha\beta}{2} \frac{\tilde{q}^2 + q_0}{1 + \beta\delta q} + \frac{\alpha}{2} \ln(1 + \beta\delta q) \\ &\quad - \frac{1}{2} \ln \delta q - \frac{1}{2} \frac{q_0 - 2m - \sigma_\omega^2 - c(m, \tilde{q})}{\delta q} \end{aligned} \quad (14)$$

3.4 Équations du col et détermination des paramètres d'ordre

Les paramètres d'ordre physiques à l'équilibre sont obtenus en annulant les dérivées partielles de l'action S_{eff}^{RS} . La dérivation par rapport à q_0 livre l'équation donnant la variance inter-répliques :

$$\frac{\partial S}{\partial q_0} = 0 \iff \frac{\alpha\beta}{2(1 + \beta\delta q)} - \frac{1}{2\delta q} = 0 \implies \delta q^* = \frac{1}{\beta(\alpha - 1)} \quad (15)$$

La minimisation par rapport à m et $\tilde{q}$ forme un système linéaire couplé. En posant $\tilde{\omega} = \tilde{q} - \bar{\omega}$, les dérivées aboutissent aux relations géométriques exactes dictées par l'inverse de la matrice A :

$$\frac{\partial S}{\partial m} = 0 \implies (A^{-1})_{11}m^* + (A^{-1})_{12}\tilde{\omega}^* = -1 \quad (16)$$

$$\frac{\partial S}{\partial \tilde{q}} = 0 \implies (A^{-1})_{12}m^* + (1 + (A^{-1})_{22})\tilde{\omega}^* = -\bar{\omega} \quad (17)$$

L'inversion de ce système fournit les valeurs optimales de projection, dépendant uniquement des invariants macroscopiques du jeu de données :

$$\tilde{q}^* = \frac{\bar{\omega} - \mathcal{J}_{\phi c}}{1 + \mathcal{J}_{\phi\phi}}, \quad m^* = \frac{\mathcal{J}_{\phi c}(\mathcal{J}_{\phi c} + \bar{\omega})}{1 + \mathcal{J}_{\phi\phi}} - \mathcal{J}_{cc} \quad (18)$$

Enfin, la dérivation par rapport à δq permet d'isoler la norme d'interaction q_0^* . Après simplification algébrique stricte, on obtient :

$$q_0^* = \frac{1}{\alpha - 1} \left[\tilde{q}^{*2} + \alpha(2m^* + \sigma_\omega^2 + c(m^*, \tilde{q}^*)) \right] \quad (19)$$

3.5 Énergie libre, erreur d'entraînement et entropie

Dans l'approximation du col (valable à la limite thermodynamique), l'énergie libre par neurone $f(\alpha, \beta)$ est donnée par la valeur de l'action au point selle divisée par β . En

y substituant les valeurs optimales, le paramètre q_0^* s'annule remarquablement, ce qui donne :

$$f(\alpha, \beta) = \frac{\alpha - 1}{2}(\tilde{q}^{*2} + 2m^* + \sigma_\omega^2 + c) + \frac{\alpha}{2\beta} \ln\left(\frac{\alpha}{\alpha - 1}\right) + \frac{1}{2\beta} \ln((\alpha - 1)\beta) \quad (20)$$

L'erreur quadratique d'entraînement moyenne $\langle \epsilon \rangle$ s'en déduit formellement via $\langle \epsilon \rangle = \partial_\beta(\beta f)$. À la limite de température nulle ($\beta \rightarrow \infty$), elle converge vers le premier terme de l'énergie libre.

Ces solutions nous donnent des informations valides et très riches pour $\alpha > 1$, mais présentent des pathologies dans le régime sous-paramétré. Ainsi la variance inter-répliques $\delta q^* = \frac{1}{\beta(\alpha-1)}$ devient négative pour $\alpha < 1$, ce qui n'a pas de sens physiquement.

Par ailleurs, l'évaluation de l'entropie thermodynamique du système, définie par $\xi = \beta^2 \frac{\partial f}{\partial \beta}$, donne :

$$\xi = \frac{\alpha - 1}{2} \ln(\alpha - 1) - \frac{\alpha}{2} \ln \alpha + \frac{1}{2} - \frac{\ln \beta}{2} \quad (21)$$

À température nulle, l'entropie diverge vers $-\infty$, signalant un effondrement non-physique de l'espace des phases et une violation du troisième principe de la thermodynamique. Ces singularités mathématiques montrent que dans le régime sur-paramétré l'état fondamental du Hamiltonien est infiniment dégénéré en l'absence de contraintes. La résolution du problème dans ce régime, si l'on ne veut pas prendre en compte le paramètre d'entraînement dans le calcul, impose l'introduction d'un terme de régularisation Ridge.

Conclusion

Ce travail de recherche a permis d'explorer les fondements théoriques de l'apprentissage de variétés non-linéaires à travers le prisme de la physique statistique. La démarche adoptée tout au long de cette année a consisté à articuler une investigation numérique systématique avec un formalisme analytique rigoureux, afin de lever le voile sur les mécanismes de généralisation dans les réseaux de neurones.

La première phase du projet a établi l'importance cruciale de la géométrie des données. En choisissant d'étudier des données générées via la rotation de templates aux topologies variées, nous avons pu isoler l'impact de la régularité spatiale sur le spectre de covariance. L'étude a révélé une dichotomie fondamentale : là où les objets géométriquement lisses présentent un effondrement spectral exponentiel, les objets présentant des discontinuités topologiques engendrent des queues lourdes algébriques. C'est cette structure spectrale que l'on retrouve dans notre problème d'apprentissage et qui explique la complexité de l'inversion de la variété par un encodeur linéaire.

Sur le plan architectural, l'échec des méthodes non-supervisées comme l'Analyse en Composantes Principales (PCA) pour dérouler la variété de manière bijective a motivé le passage à une approche supervisée et asymétrique. Nous avons démontré empiriquement qu'un encodeur linéaire (shallow) est capable d'extraire la variable latente cinématique, et donc permet une bonne reconstruction à condition que le décodeur associé soit suffisam-

ment profond pour absorber la non-linéarité de la reconstruction spatio-temporelle. Cette observation a constitué le pivot du travail, permettant de simplifier l'analyse théorique de l'apprentissage à un problème de régression linéaire traitable par les outils de la physique des systèmes désordonnés.

Les expériences numériques de gap d'échantillonnage ont servi de révélateur aux limites de la généralisation. La divergence massive de l'erreur observée pour les objets à bords francs, contrairement aux objets lisses, a mis en évidence un phénomène lié à l'indétermination des modes de hautes fréquences dans les zones non explorées. Pour expliquer ces observations, la mise en œuvre de la méthode des répliques a permis de calculer l'énergie libre et l'erreur d'entraînement dans la limite thermodynamique.

La résolution exacte sans régularisation nous a permis de calculer l'erreur d'entraînement en fonction de la covariance du template choisi, et le calcul peut à présent être prolongé pour étudier l'évolution de l'erreur de test. Les résultats de la dérivation présentée dans ce mémoire ne peuvent cependant s'appliquer qu'à la situation sous-paramétrée $\alpha > 1$; en effet toute modélisation dans le régime sur-paramétré doit prendre en compte un terme de régularisation (e.g. : régularisation Ridge), sans quoi notre solution présente une entropie infinie et négative à température nulle.

En guise de conclusion, ce projet de recherche en physique des systèmes désordonnés appliquée au machine learning a contribué à démontrer numériquement mais aussi analytiquement que la capacité d'un réseau de neurone à généraliser, bien loin d'être une capacité isolée, est le résultat d'une adéquation entre l'architecture du modèle et la régularité de l'objet physique étudié. Nos remerciements les plus chaleureux et sincères vont au Dr Remi Monasson, sans qui ce projet de recherche n'aurait jamais pu avoir lieu, ainsi qu'à l'équipe du campus Paris-Santé.

Références

- [1] Francesca Mignacco et Francesco Mori. *A statistical physics framework for optimal learning*. arXiv preprint arXiv :2507.07907, 2025.
- [2] Simona Cocco, Rémi Monasson et Francesco Zamponi. *From Statistical Physics to Data-Driven Modelling with Applications to Quantitative Biology*. Oxford University Press.
- [3] J. Steinberg, U. Adomaitytė, A. Fachechi, P. Mergny, D. Barbier et R. Monasson. *Replica method for computational problems with randomness : principles and illustrations*.
- [4] Alasdair Newson, Yann Gousseau, Andrés Almansa et Saïd Ladjal. *Processing Simple Geometric Attributes with Autoencoders*. arXiv preprint arXiv :1904.07099, 2019.
- [5] Lilian Weng. *From Autoencoder to Beta-VAE*. Lil'Log, 12 Août 2018.

4 Annexe : calcul complet des répliques

Calcul avec (Version simplifiée de Z) :

$$Z = \int dW e^{-\frac{\beta}{2} \sum_{\mu=1}^M (\omega_{\mu} - W \cdot \phi(\omega_{\mu}))^2}$$

Pour calculer $\langle \log Z \rangle$, on calcule $\langle Z^n \rangle$ pour n quelconque.

$$Z^n = \int \prod_a dW^a e^{-\frac{\beta}{2} \sum_a \sum_{\mu=1}^M (\omega_{\mu} - W^a \cdot \phi(\omega_{\mu}))^2} \quad (n \text{ répliques, } a = 1 \dots n)$$

$$\begin{aligned} \text{et } \langle Z^n \rangle &= \int \prod_a dW^a \left\langle \prod_{\mu=1}^M e^{-\frac{\beta}{2} \sum_a (\omega_{\mu} - W^a \cdot \phi(\omega_{\mu}))^2} \right\rangle \\ &= \int \prod_a dW^a \left(\left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle \right)^M \end{aligned}$$

Calcul de $\left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle$ où $W^a \cdot \phi(\omega)$.

Approximation : $\begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix}$ vecteur gaussien de corrélation $\begin{pmatrix} \mathcal{M} & C \\ C^T & \sigma_{\omega}^2 \end{pmatrix}$ et moyenne $\begin{pmatrix} \bar{\phi} \\ \bar{\omega} \end{pmatrix}$ (calculable à s_0 fixé).

$$\begin{aligned} e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} &= e^{-\frac{1}{2} \vec{u}^T (\beta \mathbb{I}_n) \vec{u}} \quad \text{avec } u^a(\omega) = \omega - W^a \cdot \phi(\omega) \\ &= \mathbb{E}_{\vec{z}} \left(e^{i \vec{u}(\omega) \cdot \vec{z}} \right) \quad \text{où } \vec{z} \text{ vecteur gaussien centré } \vec{z} \sim \mathcal{N}(\vec{0}_n, \beta \mathbb{I}_n) \end{aligned}$$

donc $\left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle = \mathbb{E}_{\vec{z}} \left(\left\langle e^{i \vec{u}(\omega) \cdot \vec{z}} \right\rangle \right)$ (Théorème de Fubini).

$$\text{Et } e^{i \sum_a z_a (\omega - W^a \cdot \phi(\omega))} = e^{i \begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix} \cdot \begin{pmatrix} -\sum_a W^a z_a \\ \sum_a z_a \end{pmatrix}}$$

donc on veut calculer $\left\langle e^{i \begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix} \cdot \begin{pmatrix} -\sum_a W^a z_a \\ \sum_a z_a \end{pmatrix}} \right\rangle$ où le vecteur $\begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix}$ est gaussien.

Calcul de la forme $\mathbb{E}(e^{i \vec{\alpha} \cdot \vec{x}})$ avec $\vec{x} \sim \mathcal{N}(\vec{\mu}, \Sigma) = e^{i \vec{\alpha} \cdot \vec{\mu} - \frac{1}{2} \vec{\alpha}^T \Sigma \vec{\alpha}}$

$$\begin{aligned}
& \text{D'où } \left\langle e^{i \begin{pmatrix} -\sum_a W^a z_a \\ \sum_a z_a \end{pmatrix} \cdot \begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix}} \right\rangle \\
&= \exp \left[-\frac{1}{2} \begin{pmatrix} -\sum_a W^a z_a \\ \sum_a z_a \end{pmatrix}^T \begin{pmatrix} \mathcal{M} & C \\ C^T & \sigma_\omega^2 \end{pmatrix} \begin{pmatrix} -\sum_a W^a z_a \\ \sum_a z_a \end{pmatrix} + i \left(\bar{\omega} \sum_a z_a - \bar{\phi} \cdot \sum_a W^a z_a \right) \right] \\
&= \exp \left[-\frac{1}{2} \begin{pmatrix} -\sum_a W^a z_a \\ -\sum_a z_a \end{pmatrix} \cdot \begin{pmatrix} -\sum_b \mathcal{M} W^b z_b + \sum_b C z_b \\ -\sum_b C \cdot W^b z_b + \sigma_\omega^2 \sum_b z_b \end{pmatrix} + i \sum_a (\bar{\omega} - W^a \cdot \bar{\phi}) z_a \right] \\
&= \exp \left[-\frac{1}{2} \sum_{a,b} \left(W^a \cdot (\mathcal{M} W^b - C) + \sigma_\omega^2 - C \cdot W^b \right) z_a z_b + i \sum_a (\bar{\omega} - W^a \cdot \bar{\phi}) z_a \right] \\
&= \exp \left[-\frac{1}{2} \sum_{a,b} \left((W^a)^T \mathcal{M} W^b - C \cdot (W^a + W^b) + \sigma_\omega^2 \right) z_a z_b + i \sum_a (\bar{\omega} - W^a \cdot \bar{\phi}) z_a \right]
\end{aligned}$$

Paramètres d'ordre :

$$\begin{aligned}
q^{a,b} &:= (W^a)^T \mathcal{M} W^b - C \cdot (W^a + W^b) + \sigma_\omega^2 \\
\tilde{q}^a &:= \bar{\omega} - \bar{\phi} \cdot W^a \\
m_a + m_b &\text{ avec } m_a = -C \cdot W^a \text{ (sorte de magnétisation)}
\end{aligned}$$

$$\text{Alors } \left\langle e^{i \sum_a z_a (\omega - W^a \cdot \phi(\omega))} \right\rangle = e^{-\frac{1}{2} \sum_{a,b} q^{a,b} z_a z_b + i \sum_a \tilde{q}^a z_a}$$

$$\begin{aligned}
\text{et } \left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle &= \mathbb{E}_{\vec{z}} \left(e^{-\frac{1}{2} \vec{z}^T q \vec{z} + i \tilde{q} \cdot \vec{z}} \right) \\
&= \mathbb{E}_{\vec{z}} \left(\mathbb{E}_{\vec{x}} (e^{i \vec{x} \cdot \vec{z}}) \right) \text{ si } \vec{x} \text{ vecteur gaussien } \sim \mathcal{N}(\tilde{q}, q) \\
&= \mathbb{E}_{\vec{x}} \left(e^{-\frac{1}{2} \vec{x}^T (\beta \mathbb{I}_n) \vec{x}} \right) \text{ car } \vec{z} \sim \mathcal{N}(\vec{0}, \beta \mathbb{I}_n) \\
&= \mathbb{E}_{\vec{x}} \left(e^{-\frac{\beta}{2} \vec{x}^2} \right)
\end{aligned}$$

$$\begin{aligned}
\text{Or } \mathbb{E}_{\vec{x}} \left(e^{-\frac{\beta}{2} \vec{x}^2} \right) &= \frac{1}{\sqrt{(2\pi)^n \det q}} \int e^{-\frac{\beta}{2} \vec{x}^2} e^{-\frac{1}{2} (\vec{x} - \tilde{q})^T q^{-1} (\vec{x} - \tilde{q})} d^n x \\
&= \frac{1}{\sqrt{(2\pi)^n \det q}} \int e^{-\frac{1}{2} (\beta \vec{x}^2 + (\vec{x} - \tilde{q})^T q^{-1} (\vec{x} - \tilde{q}))} d^n x
\end{aligned}$$

$$\begin{aligned}
&\text{Et } \beta \vec{x}^T \vec{x} + (\vec{x} - \tilde{q})^T q^{-1} (\vec{x} - \tilde{q}) \\
&= \beta \vec{x}^T \vec{x} + \vec{x}^T q^{-1} \vec{x} - \vec{x}^T q^{-1} \tilde{q} - \tilde{q}^T q^{-1} \vec{x} + \tilde{q}^T q^{-1} \tilde{q} \\
&= \vec{x}^T (q^{-1} + \beta \mathbb{I}_n) \vec{x} - 2 \vec{x}^T q^{-1} \tilde{q} + \tilde{q}^T q^{-1} \tilde{q} \\
&= (\vec{x} - \mu)^T (q^{-1} + \beta \mathbb{I}_n) (\vec{x} - \mu) + \nu
\end{aligned}$$

$$\text{avec } \mu = (\mathbb{I}_n + \beta q)^{-1} \tilde{q} \text{ et } \nu = \beta \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q}.$$

$$\begin{aligned}\Rightarrow \mathbb{E}_{\vec{x}} \left(e^{-\frac{\beta}{2} \vec{x}^2} \right) &= \frac{e^{-\nu/2}}{\sqrt{(2\pi)^n \det q}} \int e^{-\frac{1}{2} (\vec{x}-\mu)^T (q^{-1} + \beta \mathbb{I}_n) (\vec{x}-\mu)} d^n x \\ &= \frac{e^{-\nu/2}}{\sqrt{\det q \det (q^{-1} + \beta \mathbb{I}_n)}} = \frac{e^{-\nu/2}}{\sqrt{\det (\mathbb{I}_n + \beta q)}}\end{aligned}$$

et ainsi $\mathbb{E}_{\vec{x}} \left(e^{-\frac{\beta}{2} \vec{x}^2} \right) = \frac{e^{-\frac{\beta}{2} \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q}}}{\sqrt{\det (\mathbb{I}_n + \beta q)}}$

On a donc :

$$\left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle = \frac{e^{-\frac{\beta}{2} \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q}}}{\sqrt{\det (\mathbb{I}_n + \beta q)}}$$

On peut à présent calculer $\langle Z^n \rangle$ en fonction de q et $\tilde{q}$:

$$\begin{aligned}\langle Z^n \rangle &= \int \prod_a dW^a \left(\left\langle e^{-\frac{\beta}{2} \sum_a (\omega - W^a \cdot \phi(\omega))^2} \right\rangle \right)^M \\ &= \int \prod_a dW^a \frac{e^{-\frac{\beta}{2} M \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q}}}{\det (\mathbb{I}_n + \beta q)^{M/2}}\end{aligned}$$

où on rappelle que $q = q_i + q_m + \sigma_\omega^2$ avec :

$$\begin{aligned}q_i^{a,b} &:= (W^a)^T \mathcal{M} W^b \quad (\text{interaction}) \\ q_m^{a,b} &:= m_a + m_b = -C \cdot (W^a + W^b) \quad (\text{magnétisation}) \\ \tilde{q}^a &= \bar{\omega} - \bar{\phi} \cdot W^a\end{aligned}$$

Tentative de résolution de l'intégrale : Notons $G(q_i, m, \tilde{q}) := e^{-\frac{\beta}{2} M \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} - \frac{M}{2} \ln \det (\mathbb{I}_n + \beta q)}$ on veut évaluer $\int \prod_a dW^a G(q_i, m, \tilde{q})$ où $q_i, m, \tilde{q}$ sont des fonctions de W^a . Pour pouvoir intégrer sur les paramètres macroscopiques $q_i, m, \tilde{q}$ on considère que pour chaque W^a on multiplie par

$$1 = \int dx \delta(x - f(\{W^a\})) = \int dx \int d\hat{x} e^{i\hat{x}(x - f(\{W^a\}))}$$

où $\hat{x}$ est intégrée sur l'axe $i\mathbb{R}$ (à un facteur 2π près). La matrice symétrique $\hat{q}_i$ avec un facteur $\frac{1}{2}$.

$$\begin{aligned}\Rightarrow \langle Z^n \rangle &= \int dq_i d\hat{q}_i dmd\hat{m} d\tilde{q} d\hat{\tilde{q}} G(q_i, m, \tilde{q}) e^{\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) + \hat{m}^T m + \hat{\tilde{q}}^T (\tilde{q} - \bar{\omega} \mathbb{I}_n)} \\ &\quad \times \int \prod_a dW^a e^{-\frac{1}{2} \sum_{a,b} \hat{q}_i^{a,b} (W^a)^T \mathcal{M} W^b + \sum_a \hat{m}^a C \cdot W^a + \sum_a \hat{\tilde{q}}^a \bar{\phi} \cdot W^a}\end{aligned}$$

C'est-à-dire $\langle Z^n \rangle = \int dq_i d\hat{q}_i dmd\hat{m} d\tilde{q} d\hat{\tilde{q}} G(q_i, m, \tilde{q}) g(q_i, \hat{q}_i, m, \hat{m}, \tilde{q}, \hat{\tilde{q}}) \int \prod_a dW_a f(\{W_a\}, \hat{q}_i, \hat{m}, \hat{\tilde{q}})$

avec :

$$\begin{aligned} G(q_i, m, \tilde{q}) &= e^{-\frac{\beta}{2} M \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} - \frac{M}{2} \ln \det(\mathbb{I}_n + \beta q)} \\ g(q_i, \hat{q}_i, m, \hat{m}, \tilde{q}, \hat{\tilde{q}}) &= e^{\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) + \hat{m}^T m + \hat{\tilde{q}}^T (\tilde{q} - \bar{\omega} \mathbb{I}_n)} \\ f(\{W^a\}, \hat{q}_i, \hat{m}, \hat{\tilde{q}}) &= e^{-\frac{1}{2} \sum_{a,b} \hat{q}_i^{a,b} (W^a)^T \mathcal{M} W^b + \sum_a (C \hat{m}^a + \bar{\phi} \hat{\tilde{q}}^a) \cdot W^a} \end{aligned}$$

Notons $J^a := C \hat{m}^a + \bar{\phi} \hat{\tilde{q}}^a$.

Alors $\int \prod_a dW^a f(\{W^a\}, \hat{q}_i, \hat{m}, \hat{\tilde{q}}) = \int \prod_a dW^a e^{-\frac{1}{2} \sum_{a,b} \hat{q}_i^{a,b} (W^a)^T \mathcal{M} W^b + \sum_a (J^a)^T W^a}$
de la forme $\int dX e^{-\frac{1}{2} X^T A X + J^T X} = \sqrt{\frac{(2\pi)^{\dim X}}{\det A}} e^{\frac{1}{2} J^T A^{-1} J}$ avec $A = \hat{q}_i \otimes \mathcal{M}$.

$$\begin{aligned} \Rightarrow \int \prod_a dW^a f(\{W^a\}) &= \sqrt{\frac{(2\pi)^{nN}}{\det(\hat{q}_i \otimes \mathcal{M})}} e^{\frac{1}{2} \sum_{a,b} (\hat{q}_i^{-1})_{a,b} (J^a)^T \mathcal{M}^{-1} J^b} \\ &= (2\pi)^{nN/2} (\det \hat{q}_i)^{-N/2} (\det \mathcal{M})^{-n/2} e^{\dots} \end{aligned}$$

Et en développant $(J^a)^T \mathcal{M}^{-1} J^b = (C \hat{m}^a + \bar{\phi} \hat{\tilde{q}}^a)^T \mathcal{M}^{-1} (C \hat{m}^b + \bar{\phi} \hat{\tilde{q}}^b)$:

$$= \hat{m}^a C^T \mathcal{M}^{-1} C \hat{m}^b + \hat{m}^a C^T \mathcal{M}^{-1} \bar{\phi} \hat{\tilde{q}}^b + \hat{\tilde{q}}^a \bar{\phi}^T \mathcal{M}^{-1} C \hat{m}^b + \hat{\tilde{q}}^a \bar{\phi}^T \mathcal{M}^{-1} \bar{\phi} \hat{\tilde{q}}^b$$

et en sommant sur a, b :

$$= (\hat{m}^a \hat{m}^b) C^T \mathcal{M}^{-1} C + (\hat{m}^a \hat{\tilde{q}}^b + \hat{\tilde{q}}^a \hat{m}^b) \bar{\phi}^T \mathcal{M}^{-1} C + \hat{\tilde{q}}^a \hat{\tilde{q}}^b \bar{\phi}^T \mathcal{M}^{-1} \bar{\phi}$$

$$\frac{1}{2} \sum_{a,b} (\hat{q}_i^{-1})_{a,b} (J^a)^T \mathcal{M}^{-1} (J^b) = \frac{1}{2} \left((C^T \mathcal{M}^{-1} C) (\hat{m}^T \hat{q}_i^{-1} \hat{m}) + 2(\bar{\phi}^T \mathcal{M}^{-1} C) (\hat{m}^T \hat{q}_i^{-1} \hat{\tilde{q}}) + (\bar{\phi}^T \mathcal{M}^{-1} \bar{\phi}) (\hat{\tilde{q}}^T \hat{q}_i^{-1} \hat{\tilde{q}}) \right)$$

Notamment on voit apparaître les facteurs de covariance de nos données : $\mathcal{J}_{\phi\phi} := \bar{\phi}^T \mathcal{M}^{-1} \bar{\phi}$, $\mathcal{J}_{\phi c} := \bar{\phi}^T \mathcal{M}^{-1} C$, $\mathcal{J}_{cc} := C^T \mathcal{M}^{-1} C$.

Et $\int \prod_a dW^a f(\{W^a\}) = e^{\frac{1}{2} (\mathcal{J}_{cc} \hat{m}^T \hat{q}_i^{-1} \hat{m} + 2\mathcal{J}_{\phi c} \hat{m}^T \hat{q}_i^{-1} \hat{\tilde{q}} + \mathcal{J}_{\phi\phi} \hat{\tilde{q}}^T \hat{q}_i^{-1} \hat{\tilde{q}}) - \frac{N}{2} \ln \det \hat{q}_i - \frac{n}{2} \ln \det \mathcal{M}}$ (aux facteurs 2π près).

On est ainsi réduit à intégrer une expression sur les X et x , on s'est débarrassé des W^a .

À présent, $\langle Z^n \rangle = \int dq_i d\hat{q}_i dmd\hat{m} d\tilde{q} d\hat{\tilde{q}} G(q_i, m, \tilde{q}) g(q_i, \hat{q}_i, m, \hat{m}, \tilde{q}, \hat{\tilde{q}}) f(\hat{q}_i, \hat{m}, \hat{\tilde{q}})$ avec :

$$\begin{aligned} G(q_i, m, \tilde{q}) &= e^{-\frac{\beta}{2} M \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} - \frac{M}{2} \ln \det(\mathbb{I}_n + \beta q)} \\ g(q_i, \hat{q}_i, m, \hat{m}, \tilde{q}, \hat{\tilde{q}}) &= e^{\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) + \hat{m}^T m + \hat{\tilde{q}}^T (\tilde{q} - \bar{\omega} \mathbb{I}_n)} \\ f(\hat{q}_i, \hat{m}, \hat{\tilde{q}}) &= e^{\frac{1}{2} (\mathcal{J}_{cc} \hat{m}^T \hat{q}_i^{-1} \hat{m} + 2\mathcal{J}_{\phi c} \hat{m}^T \hat{q}_i^{-1} \hat{\tilde{q}} + \mathcal{J}_{\phi\phi} \hat{\tilde{q}}^T \hat{q}_i^{-1} \hat{\tilde{q}}) - \frac{N}{2} \log \det \hat{q}_i - \frac{n}{2} \log \det \mathcal{M}} \end{aligned}$$

En rassemblant tout dans une action effective :

$$\langle Z^n \rangle = \int dq_i d\hat{q}_i dmd\hat{m} d\tilde{q} d\hat{\tilde{q}} e^{-S(q_i, \hat{q}_i, m, \hat{m}, \tilde{q}, \hat{\tilde{q}})}$$

et

$$S = \frac{\beta}{2} M \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} + \frac{M}{2} \ln \det(\mathbb{I}_n + \beta q) - \frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) - \hat{m}^T m - \hat{q}^T (\tilde{q} - \bar{\omega} \mathbb{I}_n) \\ - \frac{1}{2} \mathcal{J}_{cc} \hat{m}^T \hat{q}_i^{-1} \hat{m} - \mathcal{J}_{\phi c} \hat{m}^T \hat{q}_i^{-1} \hat{\tilde{q}} - \frac{1}{2} \mathcal{J}_{\phi\phi} \hat{\tilde{q}}^T \hat{q}_i^{-1} \hat{\tilde{q}} + \frac{N}{2} \log \det \hat{q}_i + \frac{n}{2} \log \det \mathcal{M}$$

Pour continuer, on peut utiliser l'approximation du col (seuls les termes tels que $dS = 0$ contribuent significativement).

Posons $X = (m | \tilde{q} - \bar{\omega} \mathbb{I}_n)$ matrice $n \times 2$,

$J = (\hat{m} | \hat{\tilde{q}})$ matrice $n \times 2$,

$$A = \begin{pmatrix} \mathcal{J}_{cc} & \mathcal{J}_{\phi c} \\ \mathcal{J}_{\phi c} & \mathcal{J}_{\phi\phi} \end{pmatrix} \text{ matrice } 2 \times 2.$$

Alors $S = S_{\text{direct}} + S_{\text{conjugués}}$ avec :

$$S_{\text{direct}} = \frac{\beta}{2} M \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} + \frac{M}{2} \ln \det(\mathbb{I}_n + \beta q) + \frac{n}{2} \log \det \mathcal{M}$$

(Constante sans dépendance en variables conjuguées)

$$S_{\text{conjugués}} = -\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) - \hat{m}^T m - \hat{q}^T (\tilde{q} - \bar{\omega} \mathbb{I}_n) - \frac{1}{2} \mathcal{J}_{cc} \hat{m}^T \hat{q}_i^{-1} \hat{m} - \mathcal{J}_{\phi c} \hat{m}^T \hat{q}_i^{-1} \hat{\tilde{q}} - \frac{1}{2} \mathcal{J}_{\phi\phi} \hat{\tilde{q}}^T \hat{q}_i^{-1} \hat{\tilde{q}} + \frac{N}{2} \log \\ = -\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) - \text{Tr}(J^T X) - \frac{1}{2} \text{Tr}(J^T \hat{q}_i^{-1} J A) + \frac{N}{2} \log \det \hat{q}_i$$

Quand on applique la méthode du col avec les variables $\hat{\cdot}$, on ne considère que $S_{\text{conjugués}}$ (car $\frac{\partial S_{\text{direct}}}{\partial \hat{x}} \equiv 0$), qui s'écrit comme somme de traces $\Rightarrow$ dérivation facile.

Point col pour $\hat{m}$ et $\hat{\tilde{q}}$, càd pour J :

$$\frac{\partial S_{\text{conj}}}{\partial J} = 0 \Leftrightarrow -X - \hat{q}_i^{-1} J A = 0 \Leftrightarrow J = -\hat{q}_i X A^{-1}$$

Ce qui nous donne les champs $\hat{m}$ et $\hat{\tilde{q}}$. Alors

$$S_{\text{conjugués}} = -\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) + \text{Tr}(A^{-1} X^T \hat{q}_i^T X) - \frac{1}{2} \text{Tr}(A^{-1} X^T \hat{q}_i^T X) + \frac{N}{2} \log \det \hat{q}_i \\ = -\frac{1}{2} \text{Tr}(\hat{q}_i^T q_i) + \frac{1}{2} \text{Tr}(A^{-1} X^T \hat{q}_i^T X) + \frac{N}{2} \log \det \hat{q}_i$$

Point col pour $\hat{q}_i$:

$$\frac{\partial S_{\text{conj}}}{\partial \hat{q}_i} = 0 \Leftrightarrow -\frac{1}{2} q_i + \frac{1}{2} X A^{-1} X^T + \frac{N}{2} \frac{\text{Com}(\hat{q}_i)}{\det(\hat{q}_i)} = 0 \\ \Leftrightarrow -\frac{1}{2} q_i + \frac{1}{2} X A^{-1} X^T + \frac{N}{2} \hat{q}_i^{-1} = 0 \\ \Leftrightarrow \hat{q}_i^{-1} = \frac{1}{N} (q_i - X A^{-1} X^T) \\ \Leftrightarrow \hat{q}_i = N (q_i - X A^{-1} X^T)^{-1}$$

On a ainsi éliminé les champs conjugués :

$$\begin{aligned} S_{conjugués} &= -\frac{N}{2} \text{Tr} \left((q_i - XA^{-1}X^T)(q_i^T - XA^{-1}X^T)^{-1} \right) + \frac{N}{2} \text{Tr} \left(A^{-1}X^T(q_i^T - XA^{-1}X^T)^{-1}X \right) \\ &\quad + \frac{N}{2} \log \det \left(N(q_i - XA^{-1}X^T)^{-1} \right) \\ &= -\frac{N}{2} \text{Tr} \left((q_i - XA^{-1}X^T)(q_i^T - XA^{-1}X^T)^{-1} \right) + \frac{N}{2} \log \frac{N^n}{\det(q_i - XA^{-1}X^T)} \end{aligned}$$

et q_i est symétrique, donc $(q_i - XA^{-1}X^T)(q_i^T - XA^{-1}X^T)^{-1} = \mathbb{I}_{n \times n}$

et $-\frac{N}{2} \text{Tr} \left((q_i - XA^{-1}X^T)(q_i^T - XA^{-1}X^T)^{-1} \right) = -\frac{Nn}{2}$.

Ainsi $S_{conjugués} = -\frac{Nn}{2} + \frac{Nn}{2} \log N - \frac{N}{2} \log \det(q_i - XA^{-1}X^T)$.

Et, en ignorant les termes constants indépendants des paramètres d'ordre, l'action totale effective est :

$$\begin{aligned} S_{eff} &= \frac{\beta M}{2} \tilde{q}^T (\mathbb{I}_n + \beta q)^{-1} \tilde{q} + \frac{M}{2} \log \det(\mathbb{I}_n + \beta q) \\ &\quad - \frac{N}{2} \log \det \left(q_i - (m|\tilde{q} - \bar{\omega} \mathbb{I}_n) \begin{pmatrix} \mathcal{J}_{cc} & \mathcal{J}_{\phi c} \\ \mathcal{J}_{\phi c} & \mathcal{J}_{\phi\phi} \end{pmatrix}^{-1} \begin{pmatrix} m^T \\ \tilde{q}^T - \bar{\omega} \mathbb{I}_n^T \end{pmatrix} \right) \end{aligned}$$

et $\langle Z^n \rangle \propto \int dq_i dmd\tilde{q} e^{-S_{eff}}$ (avec $q = q_i + q_m + \sigma_\omega^2$).

Par la méthode du col, on peut même écrire $\langle Z^n \rangle = e^{-S_{eff}^*}$, avec $S_{eff}^* = S_{eff}(q_i^*, m^*, \tilde{q}^*)$ minimum global de S_{eff} .

On va ensuite vouloir faire $n \rightarrow 0$ et calculer $\frac{\langle Z^n \rangle - 1}{n}$ quand $n \rightarrow 0^+$.

Par confiance absolue envers le dieu des répliques, on va se permettre de prendre d'abord $n \rightarrow 0$ puis de trouver l'optimum.

Ansatz Replica Symmetry (hypothèse !) : $q_i^{a,b} = \begin{cases} Q_i & \text{si } a = b \\ q_{i0} & \text{si } a \neq b \end{cases}$

$$q^{a,b} = q_i^{a,b} + m_a + m_b + \sigma_\omega^2 = \begin{cases} Q_i + 2m + \sigma_\omega^2 & \text{si } a = b \\ q_{i0} + 2m + \sigma_\omega^2 & \text{si } a \neq b \end{cases}$$

càd $q = (Q_i - q_{i0})\mathbb{I}_{n \times n} + (q_{i0} + 2m + \sigma_\omega^2)\mathbb{J}_{n \times n}$

et $q_i = (Q_i - q_{i0})\mathbb{I}_{n \times n} + q_{i0}\mathbb{J}_{n \times n}$

$\{m^a\} = m\mathbb{K}_n$, $\{\tilde{q}^a\} = \tilde{q}\mathbb{K}_n$.

$$(m\mathbb{K}_n | (\tilde{q} - \bar{\omega})\mathbb{K}_n) A^{-1} \begin{pmatrix} m\mathbb{K}_n^T \\ (\tilde{q} - \bar{\omega})\mathbb{K}_n^T \end{pmatrix} = c\mathbb{J}_{n \times n}$$

avec $c = m^2(A^{-1})_{11} + 2m(\tilde{q} - \bar{\omega})(A^{-1})_{12} + (\tilde{q} - \bar{\omega})^2(A^{-1})_{22}$.

$$\begin{aligned}
S_{eff}^{RS} &= \frac{\beta M}{2} \tilde{q}^2 \mathbb{K}_n^T \left((1 + \beta(Q_i - q_{i0})) \mathbb{I}_{n \times n} + \beta(q_{i0} + 2m + \sigma_\omega^2) \mathbb{J}_{n \times n} \right)^{-1} \mathbb{K}_n \\
&\quad + \frac{M}{2} \log \det \left((1 + \beta(Q_i - q_{i0})) \mathbb{I}_{n \times n} + \beta(q_{i0} + 2m + \sigma_\omega^2) \mathbb{J}_{n \times n} \right) \\
&\quad - \frac{N}{2} \log \det \left((Q_i - q_{i0}) \mathbb{I}_{n \times n} + (q_{i0} - c) \mathbb{J}_{n \times n} \right)
\end{aligned}$$

Une matrice $a \mathbb{I}_{n \times n} + b \mathbb{J}_{n \times n}$ se diagonalise en base orthonormée et son inverse est $\frac{1}{a} \mathbb{I}_{n \times n} - \frac{b}{a(a+nb)} \mathbb{J}_{n \times n}$.

Donc $\mathbb{K}_n^T \left((1 + \beta(Q_i - q_{i0})) \mathbb{I}_{n \times n} + \beta(q_{i0} + 2m + \sigma_\omega^2) \mathbb{J}_{n \times n} \right)^{-1} \mathbb{K}_n$

$$\begin{aligned}
&= \mathbb{K}_n^T \left(\frac{1}{1 + \beta(Q_i - q_{i0})} \mathbb{I}_{n \times n} - \frac{\beta(q_{i0} + 2m + \sigma_\omega^2)}{[1 + \beta(Q_i - q_{i0})](1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2))} \mathbb{J}_{n \times n} \right) \mathbb{K}_n \\
&= \sum_{i,j} \left(\frac{1}{1 + \beta(Q_i - q_{i0})} \delta_{ij} - \frac{\beta(q_{i0} + 2m + \sigma_\omega^2)}{[1 + \beta(Q_i - q_{i0})](1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2))} \right) \\
&= \frac{n}{1 + \beta(Q_i - q_{i0})} - \frac{n^2 \beta(q_{i0} + 2m + \sigma_\omega^2)}{(1 + \beta(Q_i - q_{i0}))(1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2))} \\
&= \frac{n(1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2)) - n^2 \beta(q_{i0} + 2m + \sigma_\omega^2)}{(1 + \beta(Q_i - q_{i0}))(1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2))} \\
&= \frac{n}{1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2)}
\end{aligned}$$

et le 1^{er} terme de l'action effective est $\frac{\beta M}{2} \tilde{q}^2 \frac{n}{1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2)}$

Puis $\det \left((1 + \beta(Q_i - q_{i0})) \mathbb{I}_{n \times n} + \beta(q_{i0} + 2m + \sigma_\omega^2) \mathbb{J}_{n \times n} \right)$

$$= (1 + \beta(Q_i - q_{i0}))^{n-1} \cdot (1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2))$$

donc le 2^e terme est $\frac{M}{2} (n-1) \log(1 + \beta(Q_i - q_{i0})) + \frac{M}{2} \log(1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2))$

et de même $\det \left((Q_i - q_{i0}) \mathbb{I}_{n \times n} + (q_{i0} - c) \mathbb{J}_{n \times n} \right) = (Q_i - q_{i0})^{n-1} (Q_i - q_{i0} + n(q_{i0} - c))$

donc le 3^e terme est $-\frac{N}{2} (n-1) \log(Q_i - q_{i0}) - \frac{N}{2} \log(Q_i - q_{i0} + n(q_{i0} - c))$

(avec $c = m^2(A^{-1})_{11} + m(\tilde{q} - \bar{\omega})((A^{-1})_{12} + (A^{-1})_{21}) + (\tilde{q} - \bar{\omega})^2(A^{-1})_{22}$).

Ainsi, sous l'ansatz Replica Symmetry, l'action effective devient :

$$\begin{aligned}
S_{eff}^{RS}(n) &= \frac{\beta M}{2} \tilde{q}^2 \frac{n}{1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2)} \\
&\quad + \frac{M}{2} (n-1) \log(1 + \beta(Q_i - q_{i0})) + \frac{M}{2} \log(1 + \beta(Q_i - q_{i0}) + n\beta(q_{i0} + 2m + \sigma_\omega^2)) \\
&\quad - \frac{N}{2} (n-1) \log(Q_i - q_{i0}) - \frac{N}{2} \log(Q_i - q_{i0} + n(q_{i0} - c))
\end{aligned}$$

Alors à la limite $n \rightarrow 0^+$:

$$S_{eff}^{RS} \simeq_{n \rightarrow 0^+} n \left(\frac{\beta M}{2} \tilde{q}^2 \frac{1}{1 + \beta(Q_i - q_{i0})} + \frac{M}{2} \log(1 + \beta(Q_i - q_{i0})) + \frac{\beta M}{2} \frac{q_{i0} + 2m + \sigma_\omega^2}{1 + \beta(Q_i - q_{i0})} \right. \\ \left. - \frac{N}{2} \log(Q_i - q_{i0}) - \frac{N}{2} \frac{q_{i0} - c}{Q_i - q_{i0}} \right)$$

Autrement dit, avec $\alpha := \frac{M}{N}$, $\delta q := Q_i - q_{i0}$, $q_0 = q_{i0} + 2m + \sigma_\omega^2$, $\tilde{\omega} = \tilde{q} - \bar{\omega}$

$$S_{eff}^{RS} \simeq_{n \rightarrow 0^+} nN \left(\frac{\alpha\beta}{2} \frac{\tilde{q}^2}{1 + \beta\delta q} + \frac{\alpha}{2} \log(1 + \beta\delta q) + \frac{\alpha\beta}{2} \frac{q_0}{1 + \beta\delta q} - \frac{1}{2} \log \delta q - \frac{1}{2} \frac{q_{i0} - c}{\delta q} \right) \\ = nN \left(\frac{\alpha\beta}{2} \frac{\tilde{q}^2 + q_0}{1 + \beta\delta q} + \frac{\alpha}{2} \log(1 + \beta\delta q) - \frac{1}{2} \log \delta q - \frac{1}{2} \frac{q_0 - 2m - \sigma_\omega^2 - c}{\delta q} \right)$$

où on rappelle que $c(m, \tilde{q}) = (A^{-1})_{11}m^2 + 2(A^{-1})_{12}m\tilde{\omega} + (A^{-1})_{22}\tilde{\omega}^2$ donc $\begin{cases} \frac{\partial c}{\partial \tilde{q}} = 2(A^{-1})_{12}m + 2(A^{-1})_{22}\tilde{\omega} \\ \frac{\partial c}{\partial m} = 2(A^{-1})_{11}m + 2(A^{-1})_{12}\tilde{\omega} \end{cases}$

Trouvons $(\tilde{q}^*, m^*, q_0^*, \delta q^*)$ **tels que** $dS_{eff}^{RS} = 0$:

$$\frac{\partial S_{eff}^{RS}}{\partial q_0} = 0 \Leftrightarrow \frac{\alpha\beta}{2(1 + \beta\delta q^*)} - \frac{1}{2\delta q^*} = 0 \Leftrightarrow \delta q^* = \frac{1}{\beta(\alpha - 1)}$$

$$\frac{\partial S_{eff}^{RS}}{\partial m} = 0 \Leftrightarrow \frac{1}{\delta q^*} + \frac{1}{2\delta q^*} \frac{\partial c}{\partial m} = 0 \\ \Leftrightarrow \beta(\alpha - 1) + \frac{\beta(\alpha - 1)}{2} (2(A^{-1})_{11}m^* + 2(A^{-1})_{12}\tilde{\omega}^*) = 0 \\ \Leftrightarrow (A^{-1})_{11}m^* + (A^{-1})_{12}\tilde{\omega}^* = -1 \quad (1)$$

$$\frac{\partial S_{eff}^{RS}}{\partial \tilde{q}} = 0 \Leftrightarrow \frac{\alpha\beta}{1 + \beta\delta q^*} \tilde{q}^* + \frac{1}{2\delta q^*} \frac{\partial c}{\partial \tilde{q}} = 0 \\ \Rightarrow \beta(\alpha - 1)\tilde{q}^* + \beta(\alpha - 1) ((A^{-1})_{12}m^* + (A^{-1})_{22}\tilde{\omega}^*) = 0 \\ \Rightarrow \tilde{q}^* - \bar{\omega} = -((A^{-1})_{12}m^* + (A^{-1})_{22}\tilde{\omega}^*) - \bar{\omega} \\ \Leftrightarrow (A^{-1})_{12}m^* + (1 + (A^{-1})_{22})\tilde{\omega}^* = -\bar{\omega} \quad (2)$$

Le système (1) et (2) se résout en :

$$\tilde{\omega}^* = \frac{(A^{-1})_{12} - \bar{\omega}(A^{-1})_{11}}{(A^{-1})_{11} + \det A^{-1}}$$

c'est-à-dire $\tilde{q}^* = \frac{(A^{-1})_{12} + \bar{\omega} \det A^{-1}}{(A^{-1})_{11} + \det A^{-1}}$.

Or avec $A^{-1} = \frac{1}{\det A}$ com $A = \frac{1}{\det A} \begin{pmatrix} \mathcal{S}_{\phi\phi} & -\mathcal{S}_{\phi c} \\ -\mathcal{S}_{\phi c} & \mathcal{S}_{cc} \end{pmatrix}$

$$\tilde{q}^* = \frac{\bar{\omega} - \mathcal{S}_{\phi c}}{1 + \mathcal{S}_{\phi\phi}}$$

$$m^* = \frac{\mathcal{S}_{\phi c}(\mathcal{S}_{\phi c} + \bar{\omega})}{1 + \mathcal{S}_{\phi\phi}} - \mathcal{S}_{cc}$$

$$\begin{aligned} \frac{\partial S_{eff}^{RS}}{\partial \delta q} = 0 &\Leftrightarrow \frac{\alpha\beta}{2}(\tilde{q}^{*2} + q_0^*) \frac{-\beta}{(1 + \beta\delta q^*)^2} + \frac{\alpha\beta}{2} \frac{1}{1 + \beta\delta q^*} - \frac{1}{2\delta q^*} - \frac{1}{2}(q_0^* - 2m^* - \sigma_\omega^2 - c(m^*, \tilde{\omega}^*)) \frac{-1}{\delta q^{*2}} = 0 \\ &\Leftrightarrow -\frac{(\alpha-1)^2\beta^2}{2\alpha}(\tilde{q}^{*2} + q_0^*) + \frac{(\alpha-1)\beta}{2} - \frac{\beta(\alpha-1)}{2} + \frac{\beta^2(\alpha-1)^2}{2}(q_0^* - 2m^* - \sigma_\omega^2 - c) = 0 \\ &\Rightarrow \left(\frac{\beta^2(\alpha-1)^2}{2} - \frac{\beta^2(\alpha-1)^2}{2\alpha} \right) q_0^* = \frac{\beta^2(\alpha-1)^2}{2\alpha} \tilde{q}^{*2} + \frac{\beta^2(\alpha-1)^2}{2}(2m^* + \sigma_\omega^2 + c) \\ &\Rightarrow \left(1 - \frac{1}{\alpha} \right) q_0^* = \frac{1}{\alpha} \tilde{q}^{*2} + 2m^* + \sigma_\omega^2 + c(m^*, \tilde{q}^*) \\ &\Leftrightarrow q_0^* = \frac{1}{\alpha-1} \left[\tilde{q}^{*2} + \alpha(2m^* + \sigma_\omega^2 + c(m^*, \tilde{q}^*)) \right] \end{aligned}$$

Tous nos paramètres d'ordre sont ainsi explicitement donnés comme fonction de la corrélation des données !

On applique la méthode du col :

$$\langle Z^n \rangle \simeq_{n \rightarrow 0^+} e^{-n S_{eff}^{RS}(\delta q^*, q_0^*, m^*, \tilde{q}^*)}$$

et puisque $\left\langle \frac{Z^n - 1}{n} \right\rangle \xrightarrow{n \rightarrow 0^+} \langle \log Z \rangle = -\beta F$
avec $F = N \cdot f$ l'énergie libre.

Énergie libre par neurone f :

$$f = \frac{\alpha}{2} \frac{(\tilde{q}^*)^2 + q_0^*}{1 + \beta\delta q^*} + \frac{\alpha}{2} \frac{\log(1 + \beta\delta q^*)}{\beta} - \frac{1}{2\beta} \log \delta q^* - \frac{1}{2\beta} \frac{q_0^* - 2m^* - \sigma_\omega^2 - c(m^*, \tilde{q}^*)}{\delta q^*}$$

et en remplaçant δq^* par son expression $1/(\beta(\alpha-1))$:

$$f = \frac{\alpha-1}{2} ((\tilde{q}^*)^2 + q_0^*) + \frac{\alpha}{2} \frac{\log \frac{\alpha}{\alpha-1}}{\beta} + \frac{\log(\beta(\alpha-1))}{2\beta} - \frac{1}{2}(\alpha-1)(q_0^* - 2m^* - \sigma_\omega^2 - c(m^*, \tilde{q}^*))$$

→ On remarque que le paramètre d'ordre q_0^* n'intervient plus ! Interprétation ?

Ainsi, nos calculs ont montré que :

si $\begin{pmatrix} \phi(\omega) \\ \omega \end{pmatrix}$ vecteur gaussien de corrélation $\begin{pmatrix} \mathcal{M} & C \\ C^T & \sigma_\omega^2 \end{pmatrix}$ et moyenne $\begin{pmatrix} \bar{\phi} \\ \bar{\omega} \end{pmatrix}$

et $\mathcal{S}_{\phi\phi} := \bar{\phi}^T \mathcal{M}^{-1} \bar{\phi}$, $\mathcal{S}_{\phi c} := \bar{\phi}^T \mathcal{M}^{-1} C$, $\mathcal{S}_{cc} := C^T \mathcal{M}^{-1} C$, en notant :

$$\begin{aligned}\tilde{q} &:= \frac{\bar{\omega} - \mathcal{S}_{\phi c}}{1 + \mathcal{S}_{\phi\phi}} \\ m &:= \frac{\mathcal{S}_{\phi c}(\mathcal{S}_{\phi c} + \bar{\omega})}{1 + \mathcal{S}_{\phi\phi}} - \mathcal{S}_{cc} \\ c &:= \frac{1}{\mathcal{S}_{cc}\mathcal{S}_{\phi\phi} - \mathcal{S}_{\phi c}^2} (\mathcal{S}_{\phi\phi}m^2 - 2\mathcal{S}_{\phi c}m(\tilde{q} - \bar{\omega}) + \mathcal{S}_{cc}(\tilde{q} - \bar{\omega})^2)\end{aligned}$$

qui dépendent seulement de la statistique des données,
alors l'énergie libre par neurone à température inverse β est :

$$f(\alpha, \beta) = \frac{\alpha - 1}{2}(\tilde{q}^2 + 2m + \sigma_\omega^2 + c) + \frac{1}{\beta} \frac{\alpha}{2} \log \frac{\alpha}{\alpha - 1} + \frac{\log((\alpha - 1)\beta)}{2\beta}$$

On peut en déduire l'erreur d'entraînement fonction de α :

$$\langle \epsilon \rangle = \frac{\partial(\beta f)}{\partial \beta} = \frac{\alpha - 1}{2}(\tilde{q}^2 + 2m + \sigma_\omega^2 + c) + \frac{1}{2\beta}$$

et notamment à température nulle ($\beta \rightarrow \infty$),

$$\langle \epsilon \rangle = \frac{\alpha - 1}{2}(\tilde{q}^2 + 2m + \sigma_\omega^2 + c)$$

On peut aussi étudier la limite $\alpha \rightarrow 1$:

$$f(\alpha, \beta) = \frac{\tilde{q}^2 + 2m + \sigma_\omega^2 + c}{2}(\alpha - 1) + \frac{\log \beta + \alpha \log \alpha}{2\beta} - \frac{\log(\alpha - 1)}{2\beta}(\alpha - 1)$$

$\rightarrow \frac{\log \beta}{2\beta}$ pas de divergence.

Mais les paramètres d'ordre δq et q_0 divergent en $1/(\alpha - 1)!$

Et l'entropie :

$$\begin{aligned}s &= \beta^2 \frac{\partial f}{\partial \beta} = -\frac{\alpha}{2} \log \left(\frac{\alpha}{\alpha - 1} \right) - \frac{1}{2} \log(\alpha - 1) + \frac{1 - \log \beta}{2} \\ &= \frac{\alpha - 1}{2} \log(\alpha - 1) - \frac{\alpha}{2} \log \alpha + \frac{1}{2} - \frac{\log \beta}{2}\end{aligned}$$

$\rightarrow$ On voit que $s(\alpha)$ n'a pas de divergence en $\alpha \rightarrow 1$.

Mais aussi que $s(\alpha, \beta) \rightarrow -\infty$: à $T = 0$, l'entropie diverge vers $-\infty$.

On a ainsi terminé le traitement de l'erreur d'entraînement. Pour calculer l'erreur de test, il faudrait à présent reprendre le calcul avec :

$$Z(\{\omega_\mu\}) = \int dW e^{-\frac{\beta}{2} \sum_{\mu=1}^M (\omega_\mu - W \cdot \phi(\omega_\mu))^2 - \gamma (\omega_{test} - W \cdot \phi(\omega_{test}))^2}$$